

Parte 0: Construcción de la tabla analítica

```
from google.colab import files
uploaded = files.upload()
```

Elegir archivos team_1_export.zip
team_1_export.zip(application/x-zip-compressed) - 21802 bytes, last modified: 3/5/2026 - 100% done
Saving team 1 export.zip to team 1 export.zip

```
import zipfile
import os

zip_name = list(uploaded.keys())[0]

with zipfile.ZipFile(zip_name, 'r') as zip_ref:
    zip_ref.extractall("team_1_export")

print(os.listdir("team_1_export")[:10])

['Team16', 'grd_team21 (1).csv', 'Team09', 'Team07', 'Team02', 'eno_team01.csv', 'Team11', 'Team04', 'Team17', 'census_team21 (1).csv']
```

```
import pandas as pd
import glob

ruta = "team_1_export/**/*.csv"

archivos = glob.glob(ruta, recursive=True)

census_files = [f for f in archivos if "census" in f.lower()]
eno_files = [f for f in archivos if "eno" in f.lower()]
grd_files = [f for f in archivos if "grd" in f.lower()]

print("Archivos census:", len(census_files))
print("Archivos eno:", len(enos_files))
print("Archivos grd:", len(grd_files))

census_master = pd.concat([pd.read_csv(f) for f in census_files])
eno_master = pd.concat([pd.read_csv(f) for f in eno_files])
grd_master = pd.concat([pd.read_csv(f) for f in grd_files])

print("Census:", census_master.shape)
print("ENO:", eno_master.shape)
print("GRD:", grd_master.shape)
```

Archivos census: 16
Archivos eno: 16
Archivos grd: 16
Census: (38, 13)
ENO: (38, 8)
GRD: (38, 13)

```
df_final = census_master.merge(enos_master, on="codigo_comuna", how="outer")
df_final = df_final.merge(grd_master, on="codigo_comuna", how="outer")

print(df_final.shape)
df_final.head()
```

(44, 32)

	codigo_comuna	nombre_comuna_x	pop_total	pop_chilean	pop_foreign	pct_foreign	median_age_chilean	median_age_foreign	mean_schooling_chilean	mean_schooling_foreign	...	grd_chilean	g
0	5101	Valparaíso	284938	272618	12320	4.320000	36.8	30.1	11.400000	11.900000	...	22541	
1	5102	Casablanca	29876	27607	2269	7.590000	34.5	28.7	10.800000	10.300000	...	1963	
2	13101	Santiago	5806	258429	176956	3047.812608	35.0	34.0	14.421518	13.805328	...	35664	
3	13102	Cerrillos	85041	71466	12732	15.000000	36.0	34.0	11.725000	11.439000	...	6681	
4	13105	Estación Central	155257	142967	11347	7.300000	37.0	32.0	10.960000	12.194000	...	12314	
5 rows × 32 columns													

df_final.columns

```
Index(['codigo_comuna', 'nombre_comuna_x', 'pop_total', 'pop_chilean',
      'pop_foreign', 'pct_foreign', 'median_age_chilean',
      'median_age_foreign', 'mean_schooling_chilean',
      'mean_schooling_foreign', 'emp_rate_chilean', 'emp_rate_foreign',
      'dependency_ratio', 'nombre_comuna_y', 'eno_total', 'eno_chilean',
      'eno_foreign', 'eno_desconocido', 'eno_top3_diseases',
      'eno_rate_per_10k', 'nombre_comuna', 'grd_total', 'grd_chilean',
      'grd_foreign', 'grd_pct_foreign', 'grd_mean_los',
      'grd_mean_los_chilean', 'grd_mean_los_foreign', 'grd_mean_severity',
      'grd_mortality_rate', 'grd_top3_chapters', 'grd_rate_per_10k',
      'log_pop_total'],
      dtype='object')
```

```
import numpy as np
pd.set_option('display.max_columns', None)
pd.set_option('display.width', 1000)
# log población
df_final["log_pop_total"] = np.log(df_final["pop_total"])
```

```
# desempleo (ahora correcto)
df_final["pct_unemployed"] = 100 - df_final["emp_rate_chilean"]

# brecha educacional
df_final["schooling_gap"] = (
    df_final["mean_schooling_chilean"] -
    df_final["mean_schooling_foreign"]
)

df_final.head()
```


	codigo_comuna	nombre_comuna_x	pop_total	pop_chilean	pop_foreign	pct_foreign	median_age_chilean	median_age_foreign	mean_schooling_chilean	mean_schooling_foreign	emp_rate_chilean	eno_rate_per_10k	grd_rate_per_10k
0	5101	Valparaíso	284938	272618	12320	4.323748	36.8	30.1	11.400000	11.900000	53.900000	1000	1000
1	5102	Casablanca	29876	27607	2269	7.594725	34.5	28.7	10.800000	10.300000	56.400000	1000	1000
2	13101	Santiago	5806	258429	176956	3047.812608	35.0	34.0	14.421518	13.805328	72.658632	1000	1000
3	13102	Cerrillos	85041	71466	12732	14.971602	36.0	34.0	11.725000	11.439000	60.800000	1000	1000
4	13105	Estación Central	155257	142967	11347	7.308527	37.0	32.0	10.960000	12.194000	58.800000	1000	1000

```
# Parte 1.1: Matriz de correlación
import seaborn as sns
import matplotlib.pyplot as plt
vars_corr = [
    "pct_foreign",
    "log_pop_total",
    "pct_unemployed",
    "schooling_gap",
    "median_age_chilean",
    "eno_rate_per_10k",
    "grd_rate_per_10k"
]

corr = df_final[vars_corr].corr()

plt.figure(figsize=(8,6))
sns.heatmap(corr, annot=True, cmap="coolwarm", fmt=".2f")

plt.title("Matriz de Correlación")
plt.tight_layout()
plt.show()
```



Se identificó la presencia de valores atípicos extremos que distorsionaban las relaciones observadas. Al excluir estos casos, las correlaciones resultan más moderadas y plausibles, lo que nos indica que los resultados iniciales estaban fuertemente influenciados por outliers.


LIMPIEZA

```
df_clean = df_final[
    (df_final["pct_foreign"] < 100) &
    (df_final["eno_rate_per_10k"] < 2000) &
    (df_final["grd_rate_per_10k"] < 5000)
]
```

```
corr = df_clean[vars_corr].corr()

plt.figure(figsize=(8,6))
sns.heatmap(corr, annot=True, cmap="coolwarm", fmt=".2f")

plt.title("Matriz de Correlación (LIMPIA)")
plt.tight_layout()
plt.show()
```



A partir de la matriz de correlación, ahora si observamos relaciones moderadas entre las variables demográficas y los resultados de salud.

Inicialmente, los resultados estaban fuertemente influenciados por la presencia de valores atípicos extremos, lo que generaba correlaciones artificialmente altas. Al excluir estos outliers, las relaciones se vuelven más realistas y permiten una mejor interpretación de los datos.

En este contexto, se observamos que pct_foreign presenta una relación débil con las tasas de salud, lo que sugiere que su influencia es menor de lo esperado. Por otro lado, la variable schooling_gap mantiene una correlación positiva moderada con eno_rate_per_10k, lo que podría indicar que mayores brechas educacionales están asociadas a peores resultados sanitarios.




Asimismo, log_pop_total muestra una correlación negativa leve con las tasas de salud, lo que sugiere que comunas más grandes tienden a presentar menores tasas relativas, aunque la relación no es fuerte.

En general, las correlaciones son bajas a moderadas, lo que indica que los resultados de salud no dependen de una sola variable, sino de múltiples factores interrelacionados.



Finalmente, es importante destacar que estas correlaciones no implican causalidad, sino únicamente asociaciones a nivel de comuna, las cuales deben interpretarse con cautela.

SCATTER

```
for y in y_vars:
    for x in x_vars:
        plt.figure(figsize=(6,4))
        sns.regplot(data=df_clean, x=x, y=y)
        plt.title(f"{x} vs {y}")
        plt.tight_layout()
        plt.show()
```



```
x = "pct_foreign"
y = "eno_rate_per_10k"
plt.figure(figsize=(6,4))
sns.regplot(data=df_clean, x=x, y=y)
# calculamos residuos
import numpy as np
model = np.polyfit(df_clean[x], df_clean[y], 1)
pred = np.polyval(model, df_clean[x])
residuals = df_clean[y] - pred
# tomamos los 5 más extremos
extreme = residuals.abs().nlargest(5).index
for i in extreme:
    plt.text(df_clean[x][i], df_clean[y][i],
             df_clean["nombre_comuna_x"][i],
             fontsize=8)
plt.title(f"{x} vs {y} (outliers identificados)")
plt.tight_layout()
plt.show()
```



A partir de los gráficos de dispersión, se identificamos comunas que se comportan como valores atípicos, alejándose de la tendencia general observada.

En particular, la comuna de San Pedro destaca como un outlier extremo, presentando una tasa de notificación ENO considerablemente más alta que el resto, a pesar de tener un nivel moderado de población extranjera. Esto podría explicarse por factores específicos, como la concentración de casos en un centro de salud local o características demográficas particulares.

Asimismo, comunas como Valparaíso también presentan valores superiores al promedio, lo que sugiere diferencias relevantes en la dinámica de salud respecto a otras comunas.

Por otro lado, comunas como María Pinto y Alhué se ubican en la parte inferior del gráfico, reflejando menores tasas de notificación, lo que podría estar asociado a menor densidad poblacional o menor acceso a servicios de salud.

La identificación de estos valores atípicos es fundamental, ya que pueden influir significativamente en los resultados estadísticos y en la interpretación de las relaciones observadas.



```
poisson_table = modelo_poisson.summary2().tables[1]

poisson_table = poisson_table[["Coef.", "Std.Err.", "z", "P>|z|", "[0.025", "0.975]"]]

poisson_table.round(4)
```

	Coef.	Std.Err.	z	P> z	[0.025	0.975]
Intercept	-5.5766	0.0959	-58.1356	0.0000	-5.7646	-5.3886
pct_foreign	0.0092	0.0006	14.1641	0.0000	0.0079	0.0104
schooling_gap	0.2438	0.0121	20.0989	0.0000	0.2200	0.2676
pct_unemployed	-0.0004	0.0003	-1.3343	0.1821	-0.0011	0.0002
median_age_chilean	0.0208	0.0026	7.9365	0.0000	0.0156	0.0259

Modelo Poisson

Se estimó un modelo de regresión Poisson para analizar la relación entre variables demográficas y el número de casos ENO por comuna, incorporando el logaritmo de la población como offset con el fin de ajustar por el tamaño poblacional.

Los resultados nos indicaron que la variable `pct_foreign` presenta una asociación positiva y estadísticamente significativa con el número de casos ENO, lo que sugiere que comunas con mayor proporción de población extranjera tienden a registrar mayores tasas de notificación.

Asimismo, la variable `schooling_gap` muestra un efecto positivo y altamente significativo, indicando que mayores brechas educacionales entre población chilena y extranjera están asociadas a un incremento importante en los casos ENO.

Por otro lado, la variable `median_age_chilean` también presenta una asociación positiva significativa, lo que sugiere que comunas con mayor edad promedio tienden a presentar mayores niveles de notificación.

En contraste, la variable `pct_unemployed` no resulta estadísticamente significativa, lo que indica que no se observa una relación clara entre el nivel de desempleo y el número de casos ENO en este modelo.

IRR

```
import numpy as np
irr = np.exp(modelo_poisson.params)
conf = np.exp(modelo_poisson.conf_int())
irr_table = pd.DataFrame({
    "IRR": irr,
    "CI_lower": conf[0],
    "CI_upper": conf[1]
})
irr_table.round(3)
```

	IRR	CI_lower	CI_upper
Intercept	0.004	0.003	0.005
pct_foreign	1.009	1.008	1.010
schooling_gap	1.276	1.246	1.307
pct_unemployed	1.000	0.999	1.000
median_age_chilean	1.021	1.016	1.026

Interpretación de IRR: